Universidad del Norte Santo Tomás de Aquino · Ingeniería en Inteligencia Artificial · Tucumán, Argentina
Fundamentos de Ciencia de Datos · 3.er año · Observatorio de IA, edición 1 (corte 06/11/2026)

El junior de IA hoy y lo que muestran las carreras

Qué habilidades piden los avisos de nivel de entrada en roles de IA y cuánto de eso aparece en lo que publican las carreras argentinas de IA

Matías Alejandro Chalín · Lucio Agustín Sappia · Luciano Aquiles Tartarini
Docente: Rodrigo Zottola · Tucumán, noviembre de 2026

Resumen

Estudiamos si las prácticas de producción de la IA (integración, despliegue, monitoreo, nube y contenedores, y control de versiones) tienen menos evidencia publicada en los planes de estudio de carreras argentinas de IA que las habilidades de base (Python, SQL, estadística, aprendizaje automático clásico y aprendizaje profundo), aunque los avisos de nivel de entrada también las piden. Capturamos 18.206 avisos únicos de nueve fuentes el 06/11/2026, seleccionamos los de nivel de entrada de roles de IA con reglas escritas antes de mirar habilidades y obtuvimos una muestra de 97 avisos de 61 empresas. Con una línea de base automática, el 76 % de los avisos de entrada de la muestra menciona al menos una práctica de producción y el 62 % al menos una habilidad de base. Codificamos con cita textual las cinco carreras que publican contenidos por materia (cuatro instituciones): la evidencia publicada de base fue en promedio 55 puntos porcentuales mayor que la de producción ($\Delta = 0{,}55$; intervalo de confianza del 95 %: 0,30 a 0,80). Las cuatro instituciones van en el mismo sentido y el resultado se mantiene al cambiar los casos límite, pero cuatro instituciones son pocas y la lectura humana de los avisos y la segunda lectura de los planes siguen pendientes. Las otras seis carreras publican solo títulos o folletos y no pueden evidenciar prácticas de producción; se declaran como límite y no se usan en el análisis principal. El informe fija el método completo, con cada decisión justificada, para que cualquier persona pueda repetirlo.

Índice

1 Problema, pregunta e hipótesis **3**
1.1 Por qué importa . . . 3
1.2 Conceptos que usamos . . . 4
1.3 Pregunta e hipótesis . . . 4
1.4 Alcance . . . 4
1.5 Antecedentes y fuentes de referencia . . . 4

2 Datos **5**
2.1 Fuentes y método de obtención . . . 6
2.2 Aspectos legales y éticos . . . 6
2.3 Reglas de selección . . . 7
2.4 Embudo de población . . . 9

2.5 La muestra de análisis 9
2.6 Calidad de los datos y transformaciones 10
2.7 Los planes de las once carreras 10

3 Método de medición **11**
3.1 Libro de códigos 11
3.2 Línea de base y lectura humana 12
3.3 Cálculos 12
3.4 Decisiones estadísticas y su justificación 13

4 Resultados disponibles **13**
4.1 Demanda de habilidades en los avisos de entrada (línea de base) 13
4.2 Evidencia publicada en las carreras con contenidos 15
4.3 Resultado de H1 16
4.4 Avisos frente a planes, habilidad por habilidad 17

5 Validación y límites **18**
5.1 Nivel de confianza por hallazgo 18

6 Producto y validación con usuarios **19**

7 Reproducibilidad y continuidad **20**

8 Estado de los entregables y pendientes **23**

A Palabras de la línea de base (versión 1.0) **25**

B Registro de correcciones del proceso **25**

C Registro de decisiones y su justificación **26**

D Diccionario de datos de la muestra **27**

E Glosario **28**

Lectura rápida (para quien lee primero)

Qué preguntamos. Si alguien busca su primer trabajo en IA, ¿qué le piden los avisos y cuánto de eso muestran los planes de las carreras argentinas de IA?
Qué hicimos. Juntamos 18.206 avisos de empleo, nos quedamos con los de nivel de entrada de roles de IA (97 avisos, 61 empresas) y leímos con cita textual los planes de cinco carreras que publican el contenido de cada materia.
Qué encontramos. (1) Solo 12 % de los avisos de IA es de nivel de entrada. (2) Esos avisos piden a menudo prácticas de producción: despliegue (60 %), nube y contenedores (40 %), integración (34 %). (3) Los planes muestran mucho más las habilidades de base que las de producción: la diferencia promedio es de 55 puntos porcentuales (intervalo 30 a 80), y va en el mismo sentido en las cuatro instituciones.
Cómo confiar en esto. Confianza media: son pocas instituciones, los avisos se marcaron con un diccionario automático y la lectura humana sigue pendiente (sección 5.1). Publicar menos no es enseñar menos.
Qué no es. No es un ranking, no mide calidad de enseñanza ni empleo, y no vale para el mercado argentino en general.

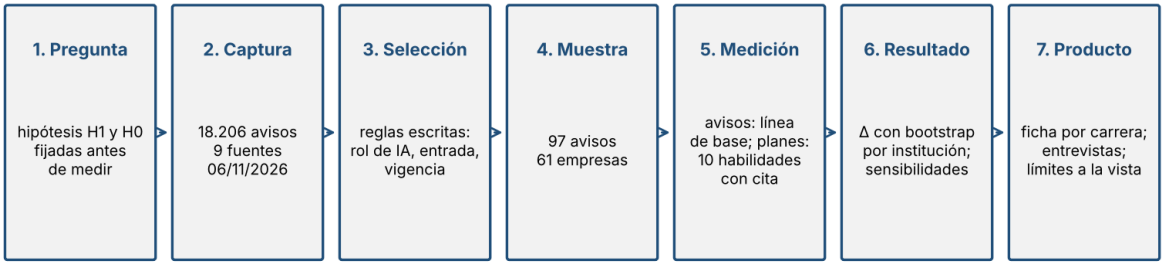


Figura 1: Recorrido completo del trabajo, de la pregunta al producto. Cada paso se detalla en las secciones 2 a 7.

1 Problema, pregunta e hipótesis

Qué hacemos y para qué. Medimos qué habilidades piden hoy los avisos de nivel de entrada en roles de IA y las comparamos con lo que publican los planes de estudio de once carreras argentinas. El resultado sirve para que una dirección de carrera vea, con fuentes y límites a la vista, qué habilidades de producción están poco documentadas en su plan. No mide empleo, calidad de la enseñanza ni aprendizaje.

1.1 Por qué importa

Un plan de estudios se diseña con años de anticipación y los puestos de entrada cambian más rápido. En los sistemas de aprendizaje automático el modelo suele ser una parte pequeña del sistema, y llevarlo a producción y mantenerlo genera trabajo propio [5, 4]. Si los avisos de entrada

piden esas tareas y los planes no las muestran, conviene saberlo con datos. Si los avisos de entrada de IA son pocos, eso también es un hallazgo.

1.2 Conceptos que usamos

- **Aviso de nivel de entrada.** Aviso cuyo texto pide como máximo 2 años de experiencia (sección 2.3). No usamos la etiqueta de nivel de las plataformas porque probamos que no es confiable.
- **Rol de IA.** Aviso cuyo título nombra un rol de IA o ciencia de datos.
- **Habilidades de base:** Python, SQL, estadística, aprendizaje automático clásico y aprendizaje profundo.
- **Habilidades de producción:** integración (conectar un modelo con otras aplicaciones, por ejemplo mediante una API), despliegue (ponerlo en el entorno donde se usa de verdad), monitoreo (controlar mientras se usa si sigue funcionando bien), nube y contenedores, y control de versiones (Git).
- **IA actual:** modelos de lenguaje, recuperación aumentada y uso de APIs de modelos. Solo se describe; no entra en la hipótesis.
- **Evidencia publicada.** Una celda carrera–habilidad vale 1 si el plan publicado muestra la habilidad y NA (información insuficiente) si no. NA nunca se cuenta como "cero" en el informe: que algo no se vea no prueba que no se enseñe.

1.3 Pregunta e hipótesis

Pregunta. ¿Qué habilidades y tareas piden hoy los avisos de nivel de entrada en roles de IA y cuánto de eso aparece en lo que publican las carreras argentinas de IA?

H1. En los planes publicados, las habilidades de producción tienen menos evidencia que las de base, aunque los avisos de nivel de entrada también piden las de producción.

H0. La evidencia publicada de producción no es menor que la de base.

Cómo se decide. Para cada carrera se calcula la proporción de habilidades de base con evidencia y la de producción con evidencia. La diferencia Δ es la media de la primera menos la media de la segunda. El intervalo de confianza del 95 % de Δ se obtiene por remuestreo (*bootstrap*) de instituciones, con 10.000 remuestreos y semilla 2026. H1 queda *sostenida* si el límite inferior es mayor que 0, *refutada* si el límite superior es menor que 0 y *sin resolver* en cualquier otro caso. Se informa la magnitud de Δ y no se inventa un umbral de "diferencia relevante".

Qué parte decide cada fuente. La diferencia entre base y producción se decide con las carreras. Los avisos solo sostienen la segunda parte ("aunque los avisos también las piden") y se describen aparte.

1.4 Alcance

Entra: avisos de nivel de entrada en roles de IA y planes publicados de once carreras. Queda fuera: salarios, calidad de la enseñanza, empleo real, rankings de universidades o de empresas y datos personales.

1.5 Antecedentes y fuentes de referencia

Estas fuentes dan contexto y justifican decisiones de diseño. No son datos del estudio y no trasladamos sus porcentajes a nuestros resultados. En la búsqueda que hicimos no encontramos

un estudio que compare, para Argentina y para el nivel de entrada, lo que piden los avisos con lo que publican los planes de las carreras de IA; por eso el aporte es acotado y lo presentamos como un relevamiento y no como una evaluación de las carreras.

Fuente	Qué respalda	Su límite para este estudio
Sculley et al. (2015) [5]	En los sistemas de aprendizaje automático el modelo es una parte pequeña y el resto (datos, integración, mantenimiento) genera deuda técnica. Justifica que las prácticas de producción merezcan medirse aparte	Es un argumento de ingeniería, no mide qué piden los avisos ni qué enseñan las carreras
Paleyes, Urma y Lawrence (2022) [4]	Revisión de casos reales de despliegue: las dificultades aparecen en cada etapa, también después de entrenar el modelo. Respalda tratar despliegue y monitoreo como habilidades propias	Reúne casos publicados, sin distinguir puestos de entrada
Shankar et al. (2022) [8]	Entrevistas a 18 ingenieros de aprendizaje automático: el éxito en producción depende de velocidad, validación y versionado. Respalda incluir el control de versiones entre las prácticas de producción	Muestra pequeña y de ingenieros con experiencia; no son puestos de entrada
Lanubile, Martínez-Fernández y Quaranta (2023) [7]	Una asignatura universitaria puede enseñar el ciclo completo de un componente de aprendizaje automático, con despliegue y monitoreo, mediante proyectos. Muestra que estas prácticas son enseñables en un curso de grado	Es un caso de dos universidades europeas con una evaluación preliminar; no describe la oferta argentina
Azuara y Jaramillo (2026) [6]	Nota técnica del BID que analiza más de 6,2 millones de vacantes digitales de 15 países de América Latina entre 2022 y 2025, con habilidades digitales y de IA. Respalda usar avisos en línea como indicador de demanda	Los avisos en línea cubren solo una parte de la demanda laboral. No se centra en el nivel de entrada de roles de IA ni compara con planes
Brown, Cai y DasGupta (2001) [1]	Márgenes de error de una proporción: fundamento de los mínimos de 30 y 100 avisos	Es un método estadístico, no una fuente sobre el tema
Efron (1979) [2]	Remuestreo (*bootstrap*) para intervalos de confianza sin suponer una distribución	Con pocos grupos (aquí cuatro instituciones) el intervalo es aproximado
Landis y Koch (1977) [3]	Interpretación del coeficiente kappa; fundamento del piso de 0,6	Sus rangos son una convención ampliamente usada, no una regla
Strathern (1997) [9]	Cuando una medida se vuelve meta deja de ser una buena medida; fundamento de no publicar rankings	Es un argumento general, no un resultado empírico sobre carreras de IA

Tabla 1: Fuentes de referencia, qué respalda cada una y su límite.

2 Datos

En una frase. de dónde salen los avisos y los planes, con qué reglas se eligen y qué sesgos tiene cada fuente.

2.1 Fuentes y método de obtención

Los métodos se declaran tal como se ejecutaron. La lectura y codificación posterior de cada aviso es manual; la captura de los avisos fue automatizada.

Fuente	Método	Avisos únicos	Observación
LinkedIn Argentina	Scraping automatizado (Apify, actor `dataji/apify-linkdin-jobs` v0.0.7), 06/11/2026, 15:11–15:17	279	648 filas brutas; aprobado por el Directorio; ver sección 2.2
Greenhouse	API pública de tableros	11.264	Tableros descubiertos en hilos de HN
Ashby	API pública de tableros	4.487	Idem
Lever	API pública de tableros	1.549	Idem
Himalayas	API pública	223	Agregador de trabajo remoto
Jobicy	API pública	133	La consulta en español dio error 400
RemoteOK	API pública	99	Agregador de trabajo remoto
Remotive	API pública	12	La API devuelve pocos avisos
Get on Board	API pública	160	Texto solo para lectura humana
Total		**18.206**	9 fuentes

Tabla 2: Fuentes, método y avisos únicos capturados.

LinkedIn. Se usó el actor de Apify "LinkedIn Jobs Scraper", que no requiere iniciar sesión y devuelve la descripción completa. Parámetros: ubicación Argentina; sin filtro de nivel de LinkedIn; exclusión de títulos con *senior, sr, lead, principal, staff, head, manager, director*; descripción completa; tope de 300 por búsqueda. Cuatro búsquedas: *machine learning*, *AI engineer*, *data scientist* e *inteligencia artificial*, que cubren los nombres más comunes del puesto en inglés y en español (decisión del equipo, no validada contra otras palabras). Resultado: 648 filas brutas y 279 avisos únicos por identificador, porque el mismo aviso aparecía en varias búsquedas. Costo: unos USD 0,60. Dos pruebas se descartaron: el filtro de nivel "Entry level" de LinkedIn (100 avisos, casi todos *Senior* o *Lead*) y el filtro por títulos con *junior, jr, entry, trainee, associate, intern* (0 avisos).

Tableros de empresas. Los enlaces a Greenhouse, Lever y Ashby se extrajeron de 36 hilos mensuales "Ask HN: Who is hiring?" con la API pública de Algolia. Se descubrieron 513 tableros; 411 respondieron y 102 ya no existen (error 404 o 410). **Sesgo declarado:** solo entran empresas que publicaron en esos hilos, en su mayoría de tecnología y de habla inglesa. Por eso los resultados globales no representan el mercado argentino y se analizan por grupo de acceso.

Buenas prácticas de captura. Nos identificamos con un *User-Agent* ("UNSTA-student-project, academic research"); hay pausas de 1 s entre pedidos (2 s en agregadores); cada respuesta se guarda sin modificar, con fecha UTC y huella SHA-256 en un manifiesto; no se recolectan datos personales y no se evaden restricciones.

2.2 Aspectos legales y éticos

- **LinkedIn.** Sus términos restringen la captura automatizada. El Directorio del Observatorio aprobó este método de captura para fines académicos. Por eso se declara como scraping automatizado y no como manual. Los textos se guardan solo en el repositorio privado del equipo; la versión pública incluye resultados agregados e identificadores.

- **Get on Board.** Su `robots.txt` declara `ai-train=no`. Por eso su texto no se procesa de forma automática: se codifica solo a mano. Del procesamiento automático solo se usa su campo estructurado de nivel (*seniority*).
- **Resto de las fuentes.** Son APIs públicas documentadas, usadas solo para investigación académica.
- **Planes de estudio.** Son páginas y PDF públicos; se citan y no se redistribuyen.

2.3 Reglas de selección

Las reglas se fijaron antes de mirar habilidades y se aplican igual a todas las fuentes. Así ningún aviso se elige por lo que menciona.

Regla	Definición	Tipo	Justificación
Rol de IA	El título contiene términos como *AI, ML, LLM, NLP, machine learning, data scientist, deep learning, inteligencia artificial, computer vision, generative, agentic*	Decisión del equipo	Es verificable y repetible. Limitación: se pierden roles con títulos genéricos; se estima con una muestra de control
Trabaja con modelos	Lectura humana: el puesto implica entrenar, evaluar, integrar o desplegar modelos	Decisión del equipo	El título solo no alcanza ("AI Sales Manager" no es un rol técnico)
Nivel de entrada	Máximo de años de experiencia mencionado en contexto de experiencia ≤ 2; se ignoran números mayores a 20	Convención y decisión	Se mide por lo que el aviso exige. Se usa el máximo y no el mínimo para que "1 a 5 años" no entre. Sensibilidad: $\leq$1, $\leq$3 y Entry+Associate
Contexto de experiencia	El número cuenta si cerca (80 caracteres) aparecen palabras como *experiencia, trabajo, background*	Decisión del equipo	Evita contar "empresa fundada hace 15 años". Sensibilidad: ventanas de 40 y 120
Get on Board	Entrada si su nivel declarado es *No experience required* o *Junior*	Convención	Es un campo estructurado; no hace falta leer el texto
Sin dato de años	Se resuelven por lectura humana	Decisión del equipo	No se asume ni entrada ni no entrada
Vigencia	Publicado hace 365 días o menos	Decisión del equipo	La pregunta es sobre "hoy"; un año cubre un ciclo de contratación. Con 180 días quedan 156 avisos y con 730, 166 (antes de limpiar)
Texto suficiente	100 palabras o más	Decisión del equipo	Con menos texto no se distingue lo que el aviso pide
Duplicados	Mismo identificador cuenta como uno; entre avisos de entrada, mismo `empresa + título` cuenta como uno	Decisión del equipo	Una vacante en varias ciudades no es evidencia nueva
Tope por empresa	Máximo 10 avisos por empresa, elegidos con semilla 2026	Decisión del equipo	Equivale al 10 % de la meta de 100 avisos. Sin tope, dos empresas ocuparían 59 de 166 avisos (36 %). Se reporta también sin tope
Grupo de acceso	Argentina; LatAm o mundial declarado; remoto sin país; otra región	Decisión del equipo	Separa lo que alcanza un egresado argentino del resto

Tabla 3: Reglas de selección, tipo de justificación y sensibilidad.

2.4 Embudo de población

Paso	Avisos
Avisos únicos capturados (9 fuentes)	18.206
Rol de IA por título	1.413
con nivel de entrada (≤2 años o declarado)	166
con nivel sin dato (a resolver por lectura humana)	496
Entrada y rol de IA, vigentes (≤365 días)	163
con texto de 100 palabras o más	161
sin repetir empresa y título	104
con tope de 10 por empresa: **muestra de análisis**	**97**

Tabla 4: Del total capturado a la muestra de análisis.

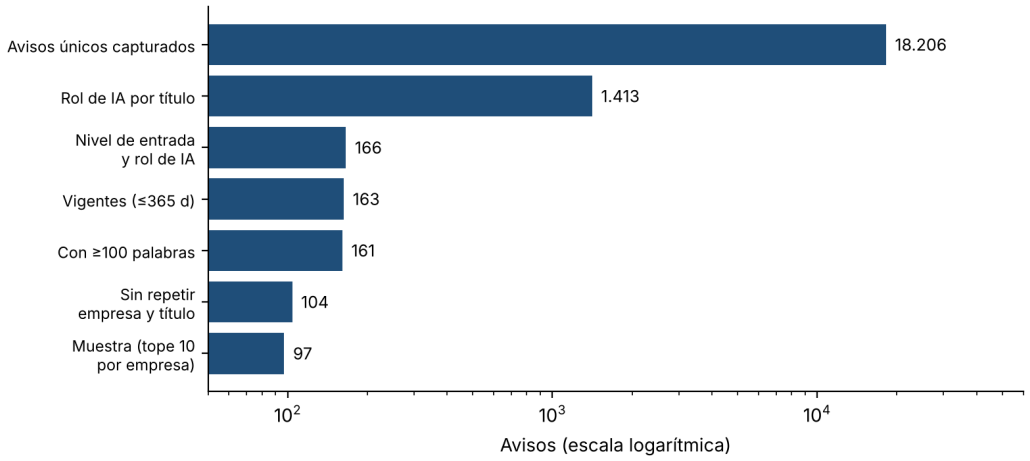


Figura 2: Embudo de selección (escala logarítmica). La mayor caída es el paso a nivel de entrada: de 1.413 avisos de IA quedan 166.

Solo el 12 % de los avisos de IA (166 de 1.413) es de nivel de entrada. Es un resultado en sí mismo.

2.5 La muestra de análisis

- **Tamaño:** 97 avisos de 61 empresas, con un máximo de 10 por empresa.
- **Fuente:** Greenhouse 42, Ashby 24, Himalayas 13, LinkedIn 12, Lever 3, Get on Board 2 y Jobicy 1.
- **Acceso:** 81 de otra región, 15 de Argentina (12 empresas) y 1 remoto sin país.
- **Idioma:** 85 en inglés y 12 en español, todos de LinkedIn. El libro de códigos cubre ambos idiomas.
- **Longitud:** mediana de 633 palabras (mínimo 104, máximo 1.878). Fechas entre 11/2025 y 11/2026.
- **Años pedidos:** 4 avisos piden 0 años, 23 piden 1 y 68 piden 2; los otros 2 son de Get on Board y se clasifican por su campo declarado.

Suficiencia. Se necesitan al menos 30 avisos para reportar un porcentaje (convención). Con 30 avisos y un porcentaje del 50 %, el margen de error del 95 % es de unos ±18 puntos; con 100, de

unos ±10 [1]. La muestra de 97 alcanza el mínimo y queda apenas por debajo de la meta de 100. Dos grupos no alcanzan el mínimo y solo se describen: los 15 avisos de Argentina y los 27 avisos que piden 1 año o menos.

2.6 Calidad de los datos y transformaciones

Antes de medir se buscaron errores, faltantes, duplicados y sesgos. Cada transformación se hizo en un script y no se modificó ningún archivo crudo.

Problema	**Qué se encontró**	**Qué se hizo**
Duplicados	LinkedIn: 648 filas brutas para 279 avisos (el mismo aviso salía en varias búsquedas). Entre avisos de entrada, 161 pasan a 104 al unir empresa y título repetidos	Se deja uno por identificador y uno por empresa y título; se informa cuántos se eliminan
Años de experiencia faltantes	5.329 avisos de la población total, y 496 de rol de IA, no mencionan años	Se clasifican “sin dato” (ni entrada ni no entrada) y se resuelven por lectura humana; no se asume nada
Años atípicos	Números como “fundada hace 25 años” o mayores a 20	Se ignoran los mayores a 20 y solo cuentan los que están cerca de palabras de experiencia
Fechas	Himalayas y Get on Board venían en segundos y se leían como milisegundos (año 1970)	Corregido; el cambio de huella quedó registrado (anexo B)
Texto muy corto	2 avisos vigentes de entrada y rol de IA tenían menos de 100 palabras	Se excluyen (regla D9)
Tableros inexistentes	102 de 513 tableros ya no existen (404 o 410)	Se registran como inexistentes; no son error del proceso
Cobertura de Argentina	Solo 15 de 97 avisos	Se describe aparte y no se generaliza
Idioma	85 en inglés y 12 en español	El diccionario cubre ambos; el límite se declara
Sesgo de fuente	Los tableros salen de empresas que publicaron en hilos de HN	Se declara y se analiza por grupo de acceso

Tabla 5: Controles de calidad, hallazgos y tratamiento.

2.7 Los planes de las once carreras

El universo son once carreras de diez instituciones (Palermo tiene dos títulos), las que el equipo pudo documentar entre el 07 y el 14/10/2026. Es un universo, no una muestra, y no se hacen pruebas de hipótesis sobre él. El nivel documental indica cuánto publica cada carrera: *identificación* (un tríptico), *listado* (títulos de materias) o *contenidos* (contenidos por materia).

Carrera	Institución	Nivel documental
Licenciatura en Inteligencia Artificial y Ciencia de Datos	UADE	contenidos
Ingeniería en Inteligencia Artificial	Palermo	contenidos
Licenciatura en Inteligencia Artificial	Palermo	contenidos
Ingeniería en Inteligencia Artificial	UNL	contenidos
Licenciatura en Inteligencia Artificial (plan 2026, Ord. 2188)	UTN-FRLP	contenidos
Ingeniería en Inteligencia Artificial	UNSTA	listado
Carrera de IA	UCA	listado
Carrera de IA	UdeSA	listado
Carrera de IA	Siglo 21	listado
Carrera de IA	UCC	listado
Carrera de IA	UCEMA	identificación

Tabla 6: Las once carreras y su nivel documental. Los nombres exactos de las seis carreras con listado o identificación se completan al cargar su ficha.

Protocolo. Se consulta el sitio oficial de cada institución. Para las cinco carreras con contenidos, el 06/11/2026 releímos directamente la página oficial del plan (UADE, Palermo, UNL) o el PDF de la ordenanza (UTN-FRLP) y registramos, para cada celda positiva, la asignatura, la cita textual y la URL (archivo `codificacion_planes.csv`). No guardamos copia con huella SHA-256 de esas páginas, así que quien repita el trabajo debe guardar su propia copia fechada y anotar si el plan cambió. La obtención es manual porque los sitios son pocos y heterogéneos (HTML, PDF, tríptico) y automatizarla no aportaría valor.

Riesgo principal: sesgo por nivel documental. Una carrera que publica solo títulos deja ver "Programación" o "Estadística", pero casi nunca "despliegue" o "monitoreo", que aparecen en los contenidos. La evidencia de producción saldría más baja por falta de detalle documental y no por falta de formación. Para evitarlo, el análisis principal de H1 usa solo las cinco carreras de nivel *contenidos* (cuatro instituciones) y las once carreras (diez instituciones) quedan como sensibilidad. La unidad de remuestreo es la institución porque las dos carreras de Palermo no son independientes. Con cuatro instituciones el intervalo será ancho; si incluye el 0, el resultado es "sin resolver" y es un resultado válido.

3 Método de medición

En una frase. qué cuenta como cada habilidad, cómo se mide y por qué se eligieron cada umbral y cada método.

3.1 Libro de códigos

Cada habilidad se codifica 1 si el texto muestra que se pide (aviso) o se enseña (plan), y 0 en un aviso si no aparece. En un plan, la ausencia de evidencia es NA. Cuenta la mención de la tarea o la herramienta como parte del trabajo; no cuenta como pedida si solo aparece en la descripción de la empresa.

Grupo	Habilidad	Cuenta cuando el texto...
Base	Python	nombra Python
Base	SQL	nombra SQL o una base de datos relacional
Base	Estadística	nombra estadística, probabilidad o pruebas de hipótesis
Base	ML clásico	nombra técnicas o bibliotecas concretas (scikit-learn, árboles, bosques aleatorios, regresiones, *clustering*); "machine learning" a secas no alcanza
Base	Aprendizaje profundo	nombra redes neuronales, *deep learning*, PyTorch, TensorFlow o Keras
Producción	Integración	pide construir o usar APIs, servicios o microservicios que conectan el modelo con otras aplicaciones
Producción	Despliegue	pide llevar o tener modelos en producción (*deploy*, CI/CD, *serving*)
Producción	Monitoreo	pide monitorear modelos o sistemas en uso (*drift*, observabilidad); "mantener" a secas no alcanza
Producción	Nube y contenedores	nombra AWS, Azure, GCP, Docker, Kubernetes o similares
Producción	Git	nombra Git, GitHub, GitLab o control de versiones
IA actual	LLM, RAG, APIs de modelos	nombra modelos de lenguaje, RAG, agentes, *prompts* o APIs de proveedores de modelos (solo descriptivo)

Tabla 7: Habilidades codificadas. La lista de palabras de la línea de base figura en el anexo A.

3.2 Línea de base y lectura humana

Línea de base. Un diccionario de palabras y expresiones en español e inglés, fijado antes de ver resultados, marca cada habilidad en cada aviso. Es rápido, repetible y burdo: puede marcar una habilidad que el aviso solo nombra de pasada y puede perder expresiones que no previmos. Por eso es una línea de base y no una medida final.

Lectura humana. Los 97 avisos de la muestra se leen dos veces, de forma independiente, por dos integrantes del equipo con asignación rotativa y semilla registrada (con 97 avisos es viable leerlos todos, así que no hace falta una submuestra). Se mide el acuerdo con el coeficiente kappa de Cohen y se exige un valor de 0,6 o más, el piso de lo que Landis y Koch llaman acuerdo sustancial [3]. Cada desacuerdo se resuelve por escrito y queda registrado.

Por qué no entrenamos un clasificador. Con 97 avisos no hay datos para entrenar y validar un modelo sin engañarnos. La línea de base validada por lectura humana es suficiente. Si la población crece a cientos de avisos, un clasificador podrá compararse contra esta línea de base.

Planes. Se leen los planes con el mismo libro de códigos y cada celda positiva lleva una cita textual con su fuente y fecha de consulta. Regla de decisión para los casos límite: una habilidad cuenta si el texto la *nombra* (por ejemplo, "SQL o "Python) o nombra una tarea que el libro de códigos define; una alusión genérica ("versionado, "lenguajes de acceso a bases de datos relacionales) no cuenta, y cada caso límite se informa y se prueba en la sensibilidad. Esta regla es estricta y puede subestimar tanto la base como la producción.

3.3 Cálculos

- **Demanda.** Porcentaje de avisos que piden cada habilidad, con intervalo del 95 %. Los avisos de una misma empresa no son independientes, así que se remuestrean empresas completas [2].
- **Cobertura y Δ.** Como se describió en la sección 1.3, con remuestreo de instituciones.

- **Sensibilidades.** Se repite el cálculo cambiando una decisión por vez y se compara con el resultado principal: ≤1 y ≤3 años; Entry+Associate; ventanas de contexto de 40 y 120 caracteres; vigencia de 180 y 730 días; sin tope por empresa; sin Get on Board; solo Argentina (descriptivo). En los planes: cambiar cada caso límite de codificación y comparar las cinco carreras de contenidos con las once (esto último queda pendiente, ver sección 8). Si el veredicto cambia en alguna, se declara frágil.

3.4 Decisiones estadísticas y su justificación

Decisión	Valor	Tipo	Por qué
Nivel de confianza	95 %	Convención	Es el valor habitual en la práctica estadística
Remuestreos	10.000	Convención	Estabiliza los extremos del intervalo; con menos, cambian de una corrida a otra
Semilla	2026	Convención	Hace repetible el resultado; el valor concreto es irrelevante
Unidad de remuestreo	Empresa (avisos); institución (planes)	Decisión del equipo	Los avisos de una empresa y las carreras de una institución no son independientes
Mínimo para un porcentaje	30 avisos	Convención	Margen de unos ±18 puntos; menos sería ruido
Meta de población	100 avisos	Decisión del equipo	Margen de unos ±10 puntos
Acuerdo entre lectores	kappa ≥ 0,6	Estándar	Acuerdo sustancial según [3]
Años de entrada	≤ 2	Convención	Es lo que suele entenderse por puesto inicial; la sensibilidad muestra cuánto depende
Diferencia relevante	Ninguna fijada	Decisión del equipo	No hay base para inventarla; se informa la magnitud y el intervalo
Entrevistas	3 a 5	Decisión del equipo	Mínimo para ver coincidencias entre más de dos personas y máximo que podemos coordinar y analizar en el plazo

Tabla 8: Umbrales estadísticos.

4 Resultados disponibles

En una frase. qué piden los avisos de entrada, qué muestran los planes y qué dice H1; todo con su nivel de confianza.

Esta sección informa solo lo que ya está medido. Los resultados que dependen de la lectura humana y de la codificación de los planes figuran como pendientes en la sección 8.

4.1 Demanda de habilidades en los avisos de entrada (línea de base)

Se aplicó el diccionario a los 95 avisos de la muestra cuyo texto puede procesarse automáticamente (se excluyen los 2 de Get on Board) y a las 59 empresas que los publican.

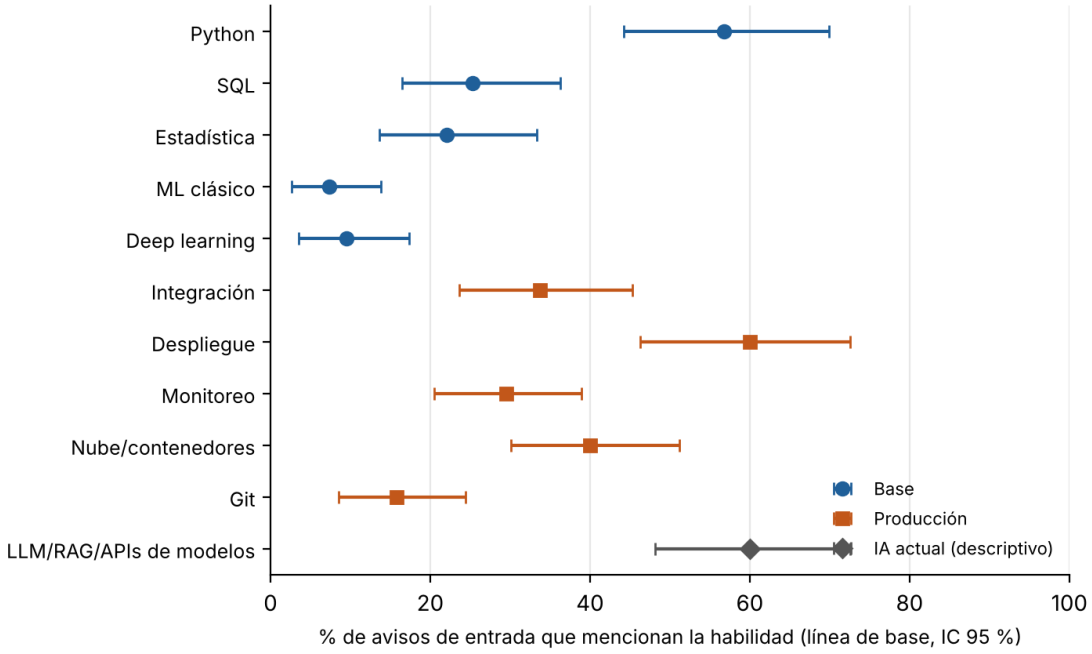


Figura 3: Porcentaje de avisos de entrada que mencionan cada habilidad, con intervalo del 95 % por remuestreo de empresas. Línea de base automática, sin validar por lectura humana.

Habilidad	Grupo	Avisos	%	IC 95 %
Python	Base	54	56,8	44,2–69,9
SQL	Base	24	25,3	16,5–36,3
Estadística	Base	21	22,1	13,6–33,3
ML clásico	Base	7	7,4	2,6–13,8
Aprendizaje profundo	Base	9	9,5	3,5–17,4
Integración	Producción	32	33,7	23,6–45,3
Despliegue	Producción	57	60,0	46,3–72,6
Monitoreo	Producción	28	29,5	20,5–38,9
Nube y contenedores	Producción	38	40,0	30,1–51,2
Git	Producción	15	15,8	8,5–24,4
LLM, RAG, APIs de modelos	IA actual	57	60,0	48,1–72,6
Al menos una de base	Resumen	59	62,1	50,0–74,7
Al menos una de producción	Resumen	72	75,8	63,4–86,5
Integración, despliegue y monitoreo a la vez	Resumen	15	15,8	9,0–24,1

Tabla 9: Demanda por habilidad en 95 avisos de entrada de 59 empresas (línea de base automática).

Lectura. Los avisos de entrada de la muestra piden con frecuencia prácticas de producción: despliegue en 60 %, nube y contenedores en 40 %, integración en 34 % y monitoreo en 30 %; Git es la menos mencionada (16 %). Esto respalda la parte “aunque los avisos de entrada también las piden”. Al menos una práctica de producción aparece en el 76 % de los avisos, frente al 62 % de al menos una de base, pero los intervalos se superponen y no corresponde afirmar una diferencia entre esos dos porcentajes. Python (57 %) es la habilidad de base más pedida. ML clásico y aprendizaje profundo salen bajos porque el diccionario exige nombrar técnicas o herramientas concretas.

Dos precauciones. (1) Es una línea de base: "despliegue" puede marcarse cuando el aviso solo dice "en producción" de forma genérica y la lectura humana puede corregirlo. (2) Solo 15 avisos son de Argentina; en ellos, 11 mencionan alguna práctica de producción y 10 alguna de base. Son conteos descriptivos que no permiten generalizar. Con el criterio de 1 año o menos (27 avisos, por debajo del mínimo de 30) el patrón es parecido: 52 % menciona alguna de base y 52 % alguna de producción, solo a modo descriptivo.

4.2 Evidencia publicada en las carreras con contenidos

Codificamos las diez habilidades en las cinco carreras de nivel *contenidos*, con el libro de códigos de la sección 3.1 y la regla de la sección 3.2. Cada celda positiva tiene asignatura, cita textual y URL en el archivo de codificación; la figura muestra el resultado.

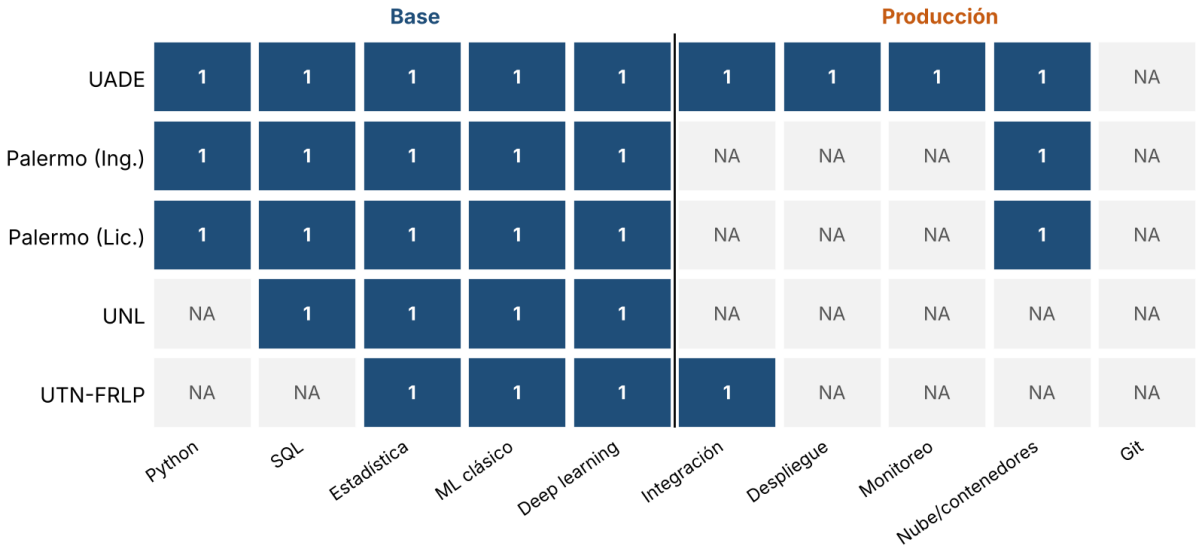


Figura 4: Evidencia publicada por carrera: 1 = el plan muestra la habilidad (con cita), NA = información insuficiente (no es "cero"). Carreras con evidencia, de 5: Python 3, SQL 4, estadística 5, ML clásico 5, aprendizaje profundo 5, integración 2, despliegue 1, monitoreo 1, nube y contenedores 3, Git 0.

La proporción de habilidades con evidencia por carrera, de base y de producción, es: UADE 1,0 y 0,8; Palermo (ambos títulos) 1,0 y 0,2; UNL 0,8 y 0,0; UTN-FRLP 0,6 y 0,2. La diferencia Δ de cada carrera es la resta: 0,2; 0,8; 0,8; 0,8 y 0,4.

Qué muestran las citas. La evidencia de despliegue y monitoreo está solo en UADE ("Seminario integrador de ciencia de datos": "Implementación y despliegue de modelos en un entorno de producción" y "Monitoreo y mantenimiento de modelos en producción"), que también nombra servicios de nube ("Canalización e integración de servicios de nube": AWS SageMaker, Google AI Platform, Azure Machine Learning). En Palermo la nube aparece como tema en "Big Data" ("Cloud. IoT") y en "Procesamiento de Lenguaje Natural" ("Servicios para procesamiento intensivo en la nube"), no como práctica de despliegue. La integración en UTN-FRLP está en el objetivo de "Visión Artificial y Lenguaje Natural" (Ordenanza 2188, p. 36): "Desarrollar aplicaciones que integren modelos de PLN y visión por computadora". Ninguna de las cinco carreras nombra Git.

Casos límite, decididos antes de calcular.

- *UADE, integración:* se codificó 1 por "Integración de tecnologías de inteligencia artificial en flujos de trabajo empresariales" (Automatización de procesos empresariales con AI). Es una alusión cercana pero no a APIs; se prueba en la sensibilidad.

- *UNL, Git:* "Versionado" (Laboratorio de Datos II) no nombra Git ni control de versiones; se codificó NA.
- *UTN-FRLP, Python y SQL:* el plan nombra scikit-learn, pandas y matplotlib (Aprendizaje Automático, p. 33) y "Lenguajes de acceso a Bases de Datos Relacionales" (p. 28), pero no "Python" ni "SQL"; se codificó NA.
- *UTN-FRLP, monitoreo:* "Monitoreo y gestión de redes" es monitoreo de redes de computadoras, no de modelos; no cuenta.
- *UNL, Python:* el plan nombra "Programación I a III" sin decir el lenguaje; NA.

4.3 Resultado de H1

Cada institución aporta un valor de Δ (Palermo promedia sus dos títulos): UADE 0,2; Palermo 0,8; UNL 0,8; UTN-FRLP 0,4. El promedio es $\Delta = 0{,}55$ (55 puntos porcentuales) con intervalo del 95 % de 0,30 a 0,80, por remuestreo de las cuatro instituciones (10.000 remuestreos, semilla 2026). Como el límite inferior es mayor que 0, según la regla fijada en la sección 1.3, H1 queda sostenida en este conjunto.

Resultado. En las cinco carreras que publican contenidos, la evidencia publicada de base supera a la de producción en 0,55 en promedio (intervalo del 95 %: 0,30 a 0,80). **H1 queda sostenida en este conjunto**, con confianza media: son cuatro instituciones y un solo lector en los planes.

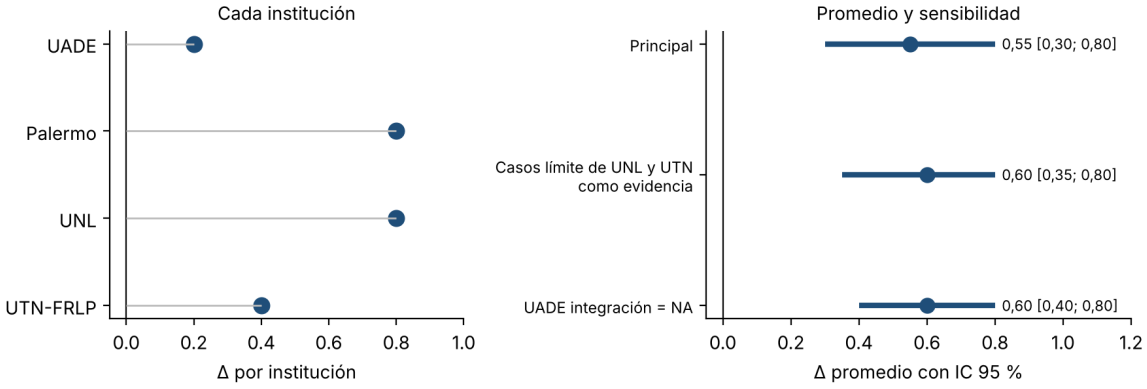


Figura 5: Δ por institución (izquierda) y promedio con intervalo del 95 % en el escenario principal y en dos escenarios de sensibilidad (derecha). La línea vertical en 0 es "sin diferencia".

Escenario	Δ	IC 95 %
Principal (codificación estricta)	0,55	0,30–0,80
Los tres casos límite de UNL y UTN-FRLP codificados como evidencia	0,60	0,35–0,80
UADE integración como NA	0,60	0,40–0,80

Tabla 10: Sensibilidad del resultado a los casos límite.

Cómo leer el resultado de H1, sin exagerar.

1. El sentido es el mismo en las cuatro instituciones ($\Delta > 0$ en todas) y en los tres escenarios; el veredicto no cambia.

2. Con solo cuatro instituciones, si las cuatro tienen $\Delta > 0$ el límite inferior queda por encima de 0 casi por construcción, y el intervalo por remuestreo es aproximado [2]. Una prueba de signos exacta con 4 de 4 daría $p = 0{,}0625$ (unilateral), por encima de 0,05. Por eso lo presentamos como un resultado consistente y acotado, no como una prueba fuerte.
3. Es un resultado sobre lo que las carreras *publican*. No dice que lo que no se publica no se enseñe, ni compara calidad de las carreras.
4. La parte "aunque los avisos de entrada también las piden" se apoya en la línea de base de la sección 4.1: despliegue 60 %, nube y contenedores 40 %, integración 34 % y monitoreo 30 % de los avisos. Esa línea aún no pasó por lectura humana.
5. La codificación de los planes fue hecha por un solo lector, asistido por una herramienta de IA, con verificación de cada cita. Falta una segunda lectura independiente de los planes, con kappa.
6. Las seis carreras restantes publican solo títulos o folletos. Con títulos no se puede evidenciar "despliegue" o "monitoreo", por eso no se usan en el análisis principal (sección 2.7). Su codificación queda como sensibilidad pendiente.

4.4 Avisos frente a planes, habilidad por habilidad

La figura siguiente junta las dos fuentes. Cada punto es una habilidad: el círculo muestra qué porcentaje de los avisos de entrada la pide y el cuadrado, qué porcentaje de las cinco carreras muestra evidencia. Son unidades distintas (avisos y carreras), por lo que la figura es descriptiva y no es una prueba.

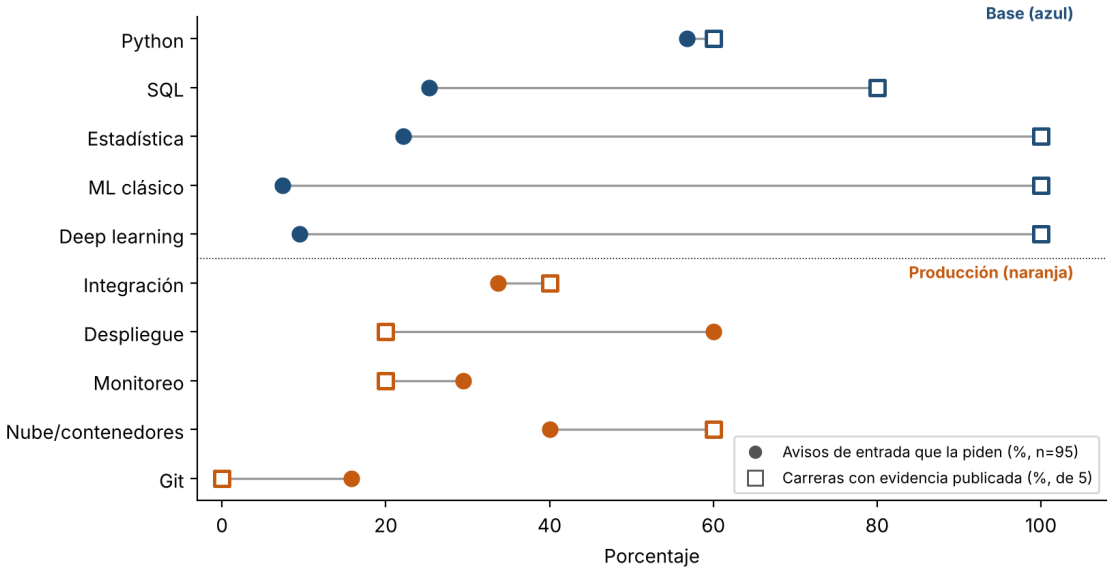


Figura 6: Demanda en avisos de entrada y evidencia publicada en los planes, por habilidad.

Lectura. En las habilidades de base los planes están muy por encima de lo que dicen los avisos (estadística, ML clásico y aprendizaje profundo aparecen en las cinco carreras; los avisos las nombran poco porque el diccionario exige términos concretos). En producción la imagen es mixta y conviene no simplificarla: *despliegue* es la habilidad con mayor distancia (60 % de los avisos y 1 de 5 carreras), *monitoreo* y *Git* también tienen poca evidencia en los planes, pero *nube y contenedores* aparece en 3 de 5 carreras, más que en la proporción de avisos (40 %). Es decir, la brecha de producción se concentra en despliegue, monitoreo y Git.

5 Validación y límites

En una frase. qué podemos afirmar, qué no, cuánto confiar en cada hallazgo y qué limita el estudio.

	Podemos afirmar	No podemos afirmar
Lo que observamos	Hay 166 avisos de entrada y de IA entre 1.413 de IA; 97 forman la muestra. Los avisos de entrada de la muestra mencionan prácticas de producción con frecuencia (línea de base). En las cinco carreras con contenidos, la evidencia publicada de base supera a la de producción en promedio por 0,55 (IC 0,30–0,80)	Que esos porcentajes sean los del mercado argentino, que la línea de base sea exacta o que el resultado valga para las seis carreras sin contenidos
Lo que inferimos, con prudencia	La distancia entre lo que piden los avisos de entrada y lo que publican los planes es mayor en producción que en base, en este conjunto	Que valga para toda Argentina ni para todos los planes: son cuatro instituciones
Lo que no afirmamos		Que una distancia entre avisos y planes sea una carencia de la formación, o que lo que no se publica no se enseñe. Esto es una asociación entre documentos, no una relación causal

Tabla 11: Qué se sostiene y qué no.

5.1 Nivel de confianza por hallazgo

Hallazgo	Confianza	Por qué
Solo 12 % de los avisos de IA capturados es de nivel de entrada	Media–alta	Conteo directo con reglas escritas; la regla de años por texto puede fallar en casos sueltos y cubre solo las fuentes capturadas
Los avisos de entrada piden con frecuencia prácticas de producción	Media	Línea de base automática sin lectura humana; "despliegue" puede marcarse por una mención genérica
Los planes con contenidos publican más base que producción ($\Delta = 0{,}55$)	Media	Mismo sentido en las cuatro instituciones y en las sensibilidades, pero son solo cuatro instituciones y un lector
La distancia se concentra en despliegue, monitoreo y Git	Media–baja	Depende de pocas carreras (despliegue y monitoreo solo en UADE) y de la regla estricta de codificación
Lo que pasa en Argentina	Baja	Solo 15 avisos; se describe y no se generaliza
Las seis carreras sin contenidos	No evaluable	Solo publican títulos o folletos

Tabla 12: Nivel de confianza (criterio del equipo, justificado en la última columna).

Limitaciones principales.

1. **Foto de un día.** Los avisos son los vigentes el 06/11/2026; otra fecha dará otros números.
2. **Sesgo de descubrimiento.** Los tableros salen de hilos de HN, con predominio de empresas anglosajonas. Argentina está subrepresentada (15 avisos).

3. **Rol por título.** Es repetible, pero pierde roles con títulos genéricos. Se estima con una muestra de control de 100 avisos no seleccionados.
4. **Años por texto.** La regla puede confundir años en el rol con experiencia total y no distingue "requerido" de "deseable". Se valida con la lectura humana.
5. **Idioma.** El 88 % de la muestra está en inglés; una diferencia entre Argentina y el resto puede mezclarse con una diferencia de idioma.
6. **LinkedIn.** Un solo país, avisos vigentes ese día y exclusión por título (senior, lead, etc.) que pudo dejar afuera algún aviso de entrada.
7. **Nivel documental.** Es el sesgo principal del lado curricular (sección 2.7) y se controla restringiendo el análisis principal.
8. **Pocas instituciones.** Son cuatro; el intervalo es aproximado y el resultado es consistente pero no concluyente (sección 4.3).
9. **Un solo lector en los planes.** La codificación la hizo una persona asistida por IA y falta segunda lectura independiente.
10. **Regla estricta.** Exigir que el plan nombre la habilidad puede subestimar la base (UTN-FRLP sin Python ni SQL) y la producción; se prueba en la sensibilidad.
11. **Conflicto de interés.** Las tres personas del equipo estudian en UNSTA, que es una de las once carreras. Su plan se codificó con las mismas reglas y no entra en el análisis principal, porque publica solo el listado de materias.
12. **Uso de herramientas de IA.** Se usó una herramienta de IA para programar, buscar y leer planes y redactar. Cada valor y cada cita se verificó contra su fuente y el equipo responde por el contenido.
13. **Fecha de publicación.** En algunas plataformas puede ser la de la última actualización.

6 Producto y validación con usuarios

En una frase. qué producto entregamos, para quién y cómo se prueba que sirve.

Producto. Una ficha por carrera, pensada para directores y coordinadores. Muestra el nivel documental, las diez habilidades (1 o NA) con la cita y fecha de cada celda positiva, y la frecuencia con que los avisos de entrada piden cada habilidad. No es un ranking de universidades ni de empresas.

Validación con usuarios. Se harán entre 3 y 5 entrevistas breves a coordinadores de carrera y estudiantes, con cinco preguntas: qué entendieron al leer la ficha por primera vez; qué decisión tomarían con ella; qué falta; qué les parece engañoso o injusto; y si la volverían a usar. Se registran las respuestas y los cambios hechos en consecuencia.

Regla de decisión sobre el valor. Si en las entrevistas menos de la mitad entiende la ficha sin ayuda o nadie dice que tomaría una decisión con ella, se revisa el alcance y el formato antes de seguir (criterio del equipo: la utilidad se valida antes de construir más y no solo al final). Cada cambio hecho por feedback se registra en la tabla siguiente.

Persona	Rol	Qué entendió y qué falta	Decisión que tomaría	Cambio hecho
E1				
E2				
E3				

Tabla 13: Registro de validación con usuarios (se completa con 3 a 5 entrevistas; hoy sin completar).

Métrica y valor. Que una carrera *publique* una habilidad no es que sus estudiantes la *aprendan*. Si la cobertura se convierte en meta, las carreras podrían agregar palabras a sus planes para "cubrir" habilidades sin cambiar lo que enseñan [9]. Por eso la ficha pide contenido por asignatura y no solo una mención, no se publica ningún ranking y se informa que mide documentación y no aprendizaje.

Versión de divulgación.

> Entre los avisos para primer empleo en IA que juntamos, muchos piden más que entrenar un modelo: piden llevarlo a producción, usarlo en la nube y conectarlo con otras aplicaciones. Al leer los planes de cinco carreras argentinas que publican el contenido de sus materias, vimos que las bases (programación, bases de datos, estadística y aprendizaje automático) están muy presentes, y que las prácticas de producción aparecen mucho menos, sobre todo despliegue, monitoreo y control de versiones. Esto no dice que esas carreras no lo enseñen: dice que no lo muestran en lo que publican. Son pocas carreras y los avisos son una foto del 06/11/2026, así que es un punto de partida para conversar y no un ranking.

Actualización futura. Proponemos repetir el relevamiento una vez por semestre (decisión del equipo: coincide con el calendario en que las carreras revisan sus planes y mantiene la comparabilidad), con las mismas reglas, semillas y diccionario, y registrar cada cambio como nueva versión del protocolo. Cada edición suma las carreras nuevas y las que hayan ampliado su información.

7 Reproducibilidad y continuidad

Qué queda registrado. Los archivos crudos sin modificar; un manifiesto con URL, fecha UTC, código HTTP, tamaño y huella SHA-256 de cada archivo; la configuración de búsquedas; las reglas con sus parámetros y semillas; el diccionario de la línea de base; las versiones de las herramientas.

Repositorio. Se entrega un repositorio privado con el informe, los datos crudos tal como los devolvió cada fuente, los manifiestos, los scripts numerados, la configuración, las tablas procesadas, los textos de la muestra y la hoja para la lectura humana (README incluido). Como incluye textos de LinkedIn y de Get on Board, no debe hacerse público; un comando genera la versión pública sin crudos ni textos, con identificadores, URL y huellas.

Tres modos de uso. *Verificar* (sin red): recalcula Δ, su intervalo y las figuras con las tablas incluidas y compara las huellas. *Reconstruir* (sin red): rehace todo desde los datos crudos y comprueba que se obtienen las mismas huellas. *Nueva edición* (con red): repite todo el recorrido cambiando la fecha de corte.

Todos los parámetros están en un solo archivo (`parametros.json`): fecha de corte, semilla, número de remuestreos, vigencia, mínimo de palabras, tope por empresa, años máximos de entrada y número de hilos de HN. Se probó que, con los parámetros de esta edición, los scripts reproducen exactamente la muestra (misma huella) y la tabla de demanda.

Paso	Qué hace	Entrada	Salida
1	Descubre tableros de empresas en los hilos de HN	Hilos mensuales	Lista de tableros
2	Captura cada tablero por su API pública	Lista de tableros	Respuestas crudas y manifiesto
3	Captura agregadores y Get on Board	Palabras clave	Respuestas crudas y manifiesto
–	Captura de LinkedIn (manual, con el actor declarado)	Cuatro búsquedas	Archivo con fecha y huella
4	Unifica las fuentes en una tabla	Crudos y manifiestos	Tabla de la API
5	Aplica reglas de rol de IA y nivel de entrada	Tabla de la API y LinkedIn	Población unificada y embudo
6	Vigencia, texto, duplicados, tope y congelado de la muestra	Población	Muestra de análisis y huella
7	Línea de base de demanda	Muestra y diccionario	Tabla de demanda
8	Cobertura de los planes, Δ, intervalo y sensibilidad	Archivo de codificación	Tablas de cobertura
9	Figuras	Resultados	Figuras del informe
10	Perfilado de los datos y métricas de la edición	Tablas procesadas	Carpeta `reports` (perfilado y `metricas.json`)
11–12	Textos y hoja de lectura humana; acuerdo (kappa) entre dos lectores	Muestra; hojas completadas	Carpeta `lectura_humana`; `acuerdo_lectura_humana.csv`

Tabla 14: Orden de ejecución, entradas y salidas.

Huellas de los archivos de este informe.

- LinkedIn limpio (279 avisos):
  `c7faf9b9d6711970941b929cd76c80bcda3e813fa1bee953f6adaf67422a2548`
- Tabla unificada sin texto (18.206 avisos):
  `30a52ba1bcc50c247ea30a122bbf2e4659640099aebedd5e70a89a12dfa5a307`
- Muestra de análisis sin texto (97 avisos):
  `e90b729bdfa8ec3a8592caaa6eb68ea04fa776d8e4d0363d3e2b026182c0e496`

Repositorio y documentación. El paquete es un repositorio de Git con historial de cambios. Además del README (orden de ejecución y archivos vigentes) incluye `docs/DATOS_ORIGEN_Y_LIMPIEZA.md` (de dónde salió cada dato, qué se hizo, qué se limpió y perfil de la muestra), `docs/DICCIONARIO_DE_DATOS.md` (columnas de cada tabla) y `CHANGELOG.md` (versión del protocolo y correcciones). La carpeta `reports` guarda el perfilado de los datos (tipos, vacíos, duplicados, distribuciones) y las métricas de la edición. El Anexo D resume la tabla de la muestra.

Continuidad, revisión entre pares y monitoreo. La línea debe poder seguir aunque sus autores dejen de participar. Los cargos del Observatorio todavía no están asignados; el documento `CONTINUIDAD_REVISION_Y_MONITOREO.md` deja el cuadro para completarlo. Antes de publicar, una persona de otra línea revisa con una lista de siete preguntas (problema claro, origen de los datos, decisiones justificadas, números coincidentes con `metricas.json`, afirmaciones acotadas, límites declarados, ausencia de daño a terceros); es una revisión breve, no un proceso formal. Para el monitoreo, como el producto es un informe y no un servicio, en cada edición se vigilan cambios

de esquema de las API, cambios de distribución respecto de la edición anterior, cambios en los planes, pérdida de acceso a una fuente y falta de uso del producto.

Cómo repetirlo en otra edición o año. Se usan las mismas cuatro palabras clave; se descubren de nuevo los tableros con los hilos del período y se registra cuántos responden; se aplican las mismas reglas y semillas sin cambiar umbrales; se guarda todo en una carpeta fechada con su manifiesto; se vuelve a consultar cada plan; y solo se comparan ediciones si reglas y fuentes son las mismas. Cualquier cambio de fuente o regla se registra como una nueva versión del protocolo.

Cómo ampliarlo. Se pueden sumar tableros, palabras clave (*data engineer, MLOps, python developer*) o zonas, justificando cada ampliación y reportando su efecto en la población.

8 Estado de los entregables y pendientes

Dónde está cada entregable final del equipo.

Entregable	Dónde
Producto final de la línea	Sección 6 (ficha por carrera) y secciones 4.2 a 4.4
Problema, preguntas, usuarios y necesidad	Secciones 1 y 6
Metodología: fuentes, calidad, preparación, técnicas, validación	Secciones 2, 3 y 5
Resultados, visualizaciones, limitaciones y confianza	Secciones 4 y 5
Validación de valor con usuarios y cambios	Sección 6 (entrevistas pendientes)
Versión de divulgación y actualización futura	Sección 6

Cumplimiento de las ocho etapas de ejecución y de los principios.

Etapa	Dónde	Pregunta de control y respuesta
1. Adquisición de datos	Sección 2	¿De dónde salió cada dato? De nueve fuentes con URL, fecha UTC y huella SHA-256 en un manifiesto; pertinente porque son avisos de empleo y planes públicos
2. Calidad y limpieza	Sección 2.6 y anexo B	¿Podemos confiar y explicar límites? Sí, con la tabla de controles y los errores corregidos
3. Análisis exploratorio	Secciones 2.4, 2.5 y 4.1	¿Qué muestran los datos? Solo 12 % de los avisos de IA es de entrada; la muestra es mayormente en inglés y de otra región
4. Análisis y modelado	Sección 3	¿La técnica ayuda? Se usan conteos, proporciones y remuestreo; no se entrena ningún modelo porque no hay datos suficientes
5. Validación de resultados	Secciones 4.3 y 5	¿Qué es exagerar? Decir que los planes no enseñan producción, o que valga para Argentina. Todo es asociación entre documentos, no causalidad ni predicción
6. Producto y prueba	Sección 6	¿Alguien externo lo entiende? Pendiente: entrevistas
7. Revisión interna	Anexos B y C	¿Podemos rastrear cada resultado? Sí, hasta archivo, cita y URL; falta segunda lectura humana
8. Publicación y divulgación	Lectura rápida y sección 6	¿Simplifica sin distorsionar? La versión de divulgación declara los límites
Rigurosidad, trazabilidad, reproducibilidad, transparencia, relevancia	Secciones 5, 2, 7, 5 y 1	Afirmaciones acotadas; manifiesto y citas; paquete de reproducción; límites y conflicto de interés declarados; pregunta ligada a una decisión de las direcciones de carrera

Tabla 15: Cómo responde este informe a cada etapa y principio de la ejecución.

Versiones del informe. Técnica: el documento completo. Ejecutiva: la lectura rápida del inicio. Divulgación: la caja de la sección 6.

Qué no sabemos todavía.

- Si lo que piden los avisos coincide con la lectura humana (la línea de base es automática).
- Qué pasa en las seis carreras que publican solo títulos o folletos.
- Qué enseñan realmente las cinco carreras: solo conocemos lo que publican.

- Si la ficha por carrera es entendida y útil para quien debe decidir.
- Cuántos avisos de IA sin dato de años (496) son en verdad de nivel de entrada.

Qué debería investigar o mejorar la línea a continuación. Completar la lectura humana y la segunda lectura de planes; ampliar a las once carreras; sumar fuentes con más avisos de Argentina; entrevistar a coordinadores y estudiantes; y repetir el relevamiento cada semestre para ver la evolución.

Estado.

Entregable	Estado	Qué falta
Foco, hipótesis y método	Hecho	
Captura y selección de avisos	Hecho	Resolver por lectura los 467 avisos de IA sin dato de años
Línea de base de demanda	Hecho	Validar con lectura humana
Lectura humana doble y kappa	Pendiente	Leer los 97 avisos; kappa $\geq 0{,}6$
Muestra de control del filtro por título	Pendiente	Leer 100 avisos no seleccionados
Codificación de los planes con las diez habilidades	Hecho para 5 de 11	Segunda lectura independiente; codificar las seis carreras con listado o identificación como sensibilidad
Cálculo de Δ y sensibilidades	Hecho para 5 de 11	Repetir tras la segunda lectura y con las once carreras
Aprobación del Directorio para LinkedIn	A completar	Registrar fecha y número de acta
Ficha por carrera y entrevistas	Pendiente	3 a 5 entrevistas
Artículo individual y presentación de 15 minutos	Pendiente	Una vez calculado Δ

Tabla 16: Estado del trabajo.

Referencias

[1] Brown, L. D., Cai, T. T. y DasGupta, A. (2001). Interval estimation for a binomial proportion. *Statistical Science*, 16(2), 101–133.

[2] Efron, B. (1979). Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, 7(1), 1–26.

[3] Landis, J. R. y Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1), 159–174.

[4] Paleyes, A., Urma, R.-G. y Lawrence, N. D. (2022). Challenges in deploying machine learning: a survey of case studies. *ACM Computing Surveys*, 55(6). arXiv:2011.09926.

[5] Sculley, D. et al. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, 28.

[6] Azuara Herrera, O. y Jaramillo Vasconez, O. E. (2026). *What jobs are being created in Latin America? Analysis of online job postings in Latin America and the Caribbean.* Nota técnica IDB-TN-03283, Banco Interamericano de Desarrollo.

[7] Lanubile, F., Martínez-Fernández, S. y Quaranta, L. (2023). Teaching MLOps in higher education through project-based learning. *IEEE/ACM 45th International Conference on Software Engineering: Software Engineering Education and Training (ICSE-SEET)*. arXiv:2302.01048.

[8] Shankar, S., Garcia, R., Hellerstein, J. M. y Parameswaran, A. G. (2022). Operationalizing machine learning: an interview study. arXiv:2209.09125.

[9] Strathern, M. (1997). “Improving ratings”: audit in the British University system. *European Review*, 5(3), 305–321.

A Palabras de la línea de base (versión 1.0)

El diccionario está en español e inglés y se aplica sobre el texto en minúsculas. La versión exacta con expresiones regulares forma parte del repositorio.

Habilidad	Palabras y expresiones
Python	python
SQL	sql, postgres, mysql
Estadística	statistic, estadístic, hypothesis test, prueba de hipótesis, probabilit, probabilidad
ML clásico	scikit, sklearn, xgboost, lightgbm, random forest, gradient boost, decision tree, árbol de decisión, logistic regression, linear regression, regresión, clustering, svm
Aprendizaje profundo	deep learning, aprendizaje profundo, neural net, red neuronal, pytorch, tensorflow, keras
Integración	api, rest, restful, fastapi, flask, grpc, microservic
Despliegue	deploy, despleg, in production, en producción, a producción, ci/cd, model serving, mlops
Monitoreo	monitor, observabilit, drift, prometheus, grafana
Nube y contenedores	aws, azure, gcp, google cloud, docker, kubernetes, k8s, cloud, nube, contenedor, sagemaker, vertex
Git	git, github, gitlab, bitbucket, control de versiones, version control
IA actual	llm, large language model, rag, retrieval-augmented, prompt, openai, anthropic, langchain, llamaindex, generative ai, genai, ia generativa, agent, agéntic

Tabla 17: Diccionario de la línea de base.

B Registro de correcciones del proceso

Los controles de verificación detectaron y corrigieron estos errores durante el trabajo. Ninguno cambió una conclusión, pero se registran para que el proceso sea trazable.

Qué	Error	Corrección
Años sin dato	Los avisos sin mención de años se clasificaban como “no entrada” (5.489 avisos)	Pasan a la categoría “sin dato” (5.329 avisos en total)
Fechas	Las fechas de Himalayas y Get on Board venían en segundos y se leían como milisegundos (año 1970)	Se convirtieron bien; cambió la huella de la tabla unificada
Tableros	Se había contado 413 tableros respondidos	Son 411 los tableros que respondieron (más el manifiesto y el registro, que suman 413 archivos)

C Registro de decisiones y su justificación

Cada decisión tiene un tipo: *estándar* (lo fija una fuente reconocida), *convención* (práctica habitual sin fuente única) o *decisión del equipo* (elegida por nosotros y justificada). La última columna dice cómo se prueba o qué pasa si se cambia.

ID	Decisión	Tipo	Justificación	Si se cambia
D1	Fuentes de avisos: 9	Equipo	Mezcla un portal con alcance en Argentina (LinkedIn) y APIs públicas que se pueden capturar de forma repetible y sin evadir restricciones	Se analiza por grupo de acceso; sin Get on Board
D2	Descubrir tableros en 36 hilos de HN	Equipo	Tres años de hilos mensuales dan cientos de empresas sin pedir permisos; sesgo declarado hacia empresas de tecnología en inglés	Parámetro `n_hilos_hn`
D3	Cuatro palabras clave	Equipo	Cubren los nombres comunes del puesto en inglés y español; no se validaron contra otras	Se pueden sumar (data engineer, MLOps)
D4	Excluir títulos senior, lead, etc. en LinkedIn	Equipo	El filtro de nivel de la plataforma no es confiable (se probó); se evita traer avisos que no serían de entrada	Pudo dejar afuera algún aviso de entrada (límite 6)
D5	Rol de IA por título	Equipo	Verificable y repetible; limitación: pierde títulos genéricos	Muestra de control de 100 avisos
D6	Nivel de entrada: máximo de años ≤ 2 en contexto de experiencia	Convención y equipo	Se mide lo que el aviso exige; el máximo evita que “1 a 5 años” entre	Sensibilidad ≤ 1, ≤ 3, Entry+Associate
D7	Ventana de contexto de 80 caracteres	Equipo	Evita contar años que no son de experiencia	Sensibilidad 40 y 120
D8	Vigencia de 365 días	Equipo	La pregunta es sobre “hoy”; un año cubre un ciclo de contratación	Sensibilidad 180 y 730
D9	Mínimo de 100 palabras	Equipo	Con menos texto no se distingue lo que se pide	Parámetro `min_palabras`
D10	Duplicados por empresa y título	Equipo	Una vacante en varias ciudades no es evidencia nueva	Se informa cuántos se eliminan
D11	Tope de 10 avisos por empresa	Equipo	10 % de la meta de 100; sin tope, dos empresas serían el 36 %	Sensibilidad sin tope
D12	Diccionario de la línea de base v1.0	Equipo	Fijado antes de ver resultados; burdo a propósito: se corrige con lectura humana	Cambios = nueva versión
D13	Mínimo de 30 avisos para un porcentaje y meta de 100	Convención y equipo	Márgenes de unos ± 18 y ± 10 puntos [1]	Grupos menores solo se describen
D14	IC del 95 %, 10.000 remuestreos, semilla 2026	Convención	Valores habituales; la semilla hace repetible el resultado	Parámetros del archivo
D15	Remuestrear empresas (avisos) e instituciones (planes)	Equipo	Los avisos de una empresa y las carreras de una institución no son independientes [2]	Con 4 instituciones el IC es aproximado
D16	Δ = media de proporciones de base menos de producción	Equipo	Pondera igual cada habilidad y no inventa pesos; permite comparar carreras con distinta cantidad de habilidades codificadas	Se informa también por habilidad (figura de avisos frente a planes)

ID	Decisión	Tipo	Justificación	Si se cambia
D17	Regla de decisión por el IC (sostenida, refutada, sin resolver)	Equipo	Se fija antes de calcular y no usa un umbral de diferencia relevante inventado	—
D18	Celda = 1 o NA, nunca 0	Equipo	No ver algo en un plan no prueba que no se enseñe	NA se cuenta como sin evidencia solo en el cálculo
D19	Análisis principal con las 5 carreras de contenidos	Equipo	Con solo títulos no se puede evidenciar despliegue o monitoreo (sesgo documental)	Sensibilidad con las 11 (pendiente)
D20	Codificación estricta: la habilidad debe nombrarse	Equipo	Evita interpretar de más; es repetible por otra persona	Casos límite probados en la sensibilidad
D21	Palermo cuenta como una institución	Equipo	Sus dos títulos comparten plan y no son independientes	Contar 2 unidades daría el mismo sentido
D22	Kappa $\geq$ 0,6	Estándar	Acuerdo sustancial [3]	Si no se alcanza, se ajusta el libro de códigos
D23	Leer los 97 avisos dos veces	Equipo	Con 97 avisos es viable y evita submuestrear	—
D24	No entrenar un clasificador	Equipo	Con 97 avisos no hay datos para entrenar y validar sin engañarse	Revisar si la población llega a cientos
D25	3 a 5 entrevistas	Equipo	Mínimo para ver coincidencias entre más de dos personas y máximo coordinable	Se amplía si hay desacuerdos grandes
D26	No publicar rankings	Equipo	Una medida que se vuelve meta deja de ser buena [9]	—
D27	Actualización semestral	Equipo	Coincide con el calendario en que las carreras revisan planes y mantiene la comparabilidad	Se puede espaciar
D28	LinkedIn por scraping automatizado, aprobado por el Directorio	Equipo	Es el único portal con alcance en Argentina; se declara tal como se hizo	Fecha y acta a completar
D29	Get on Board: texto solo para lectura humana	Estándar	Su `robots.txt` declara `ai-train=no`	—

D Diccionario de datos de la muestra

Tabla `avisos_muestra_analisis.csv` (97 filas; una fila es un aviso). La población unificada tiene las mismas columnas hasta `acceso`. El diccionario completo de todas las tablas está en el repositorio.

Columna	Tipo	Significado
`id_unico`	texto	Fuente e identificador del aviso
`fuente`, `metodo_captura`	texto	Plataforma y modo de captura (API pública o scraping)
`fecha_captura`, `sha256_origen`	fecha, texto	Cuándo se pidió y huella del archivo crudo de origen
`url`	texto	Enlace público del aviso
`fecha_publicacion`	fecha	Según la plataforma
`titulo`, `empresa`, `ubicacion`	texto	Tal como los publica la fuente
`modalidad`, `nivel_declarado`	texto	Declarados por la fuente; con muchos vacíos; no se usan para clasificar
`codificacion_solo_humana`	lógico	Verdadero en Get on Board (`ai-train=no`)
`rol_ia_titulo`	lógico	El título contiene un término de rol de IA
`anios_req`	número	Máximo de años pedidos en contexto de experiencia; vacío si no se informa
`nivel_regla`	texto	Entrada, no entrada o sin dato, según la regla
`acceso`	texto	Argentina, remoto sin país u otra región
`idioma`, `palabras`, `dias`	texto, número	Idioma, largo del texto y antigüedad al corte
`clave`	texto	Empresa y título normalizados (control de duplicados)

Tabla 19: Columnas de la muestra de análisis.

E Glosario

Aviso de nivel de entrada
Aviso que pide como máximo 2 años de experiencia, según su texto.

Bootstrap (remuestreo)
Repetir el cálculo muchas veces sobre grupos elegidos al azar con reposición para ver cuánto cambia el resultado; sirve para el intervalo de confianza.

Cobertura publicada
Si el plan de una carrera muestra una habilidad. No es lo mismo que lo que se aprende.

Δ Proporción de habilidades de base con evidencia menos proporción de habilidades de producción con evidencia, por carrera.

Intervalo de confianza del 95 %
Rango de valores compatibles con los datos; si no incluye el 0, la diferencia no se explica solo por azar de muestreo.

Kappa Medida de acuerdo entre dos lectores que descuenta el acuerdo por azar.

Línea de base Primera medición automática, rápida y burda, que luego se corrige con lectura humana.

NA Información insuficiente. No es “cero”: no ver algo en un plan no prueba que no se enseñe.

Nivel documental
Cuánto publica una carrera: identificación, listado de materias o contenidos por materia.

Producción (prácticas de)
Integración, despliegue, monitoreo, nube y contenedores, y control de versiones.